

■ LEIA ANTES DE USAR

CHAT-IA-USB

LEITURA OBRIGATÓRIA

NÃO EXECUTE, NÃO INSTALE E NÃO ALTERE A CONFIGURAÇÃO DO PROJETO ANTES DE LER ESTE DOCUMENTO E O README.md.

Este PDF foi criado como um aviso de segurança e orientação inicial. A finalidade é impedir que o usuário execute scripts, abra portas ou modifique o pendrive sem primeiro compreender o projeto.

1. ORDEM OBRIGATÓRIA DE LEITURA

PASSO 1 — LEIA ESTE PDF.

Entenda os avisos, riscos, Internet, servidor local, porta 8080 e pendrive.

PASSO 2 — LEIA O README.md.

O README contém a apresentação do projeto, instalação, execução, requisitos, estrutura, fontes e orientações.

PASSO 3 — LEIA:

docs/COMO-FUNCIONA-E-SEGURANCA.md

Esse documento explica em profundidade o funcionamento, Internet, modo offline, llamafile, modelo GGUF, servidor HTTP, 127.0.0.1, porta 8080, firewall, CORS, privacidade, limitações e segurança.

PASSO 4 — SOMENTE DEPOIS execute os scripts.

2. NÃO EXECUTE IMEDIATAMENTE

Não faça simplesmente: **baixar** → **clicar em iniciar.bat**. Primeiro leia a documentação. Este projeto executa software no computador e carrega um modelo de Inteligência Artificial.

3. INTERNET E IA LOCAL

A instalação pode precisar de Internet para baixar o llamafile e o modelo. Depois que os componentes estiverem armazenados localmente, a inferência pode ser executada sem Internet, conforme a configuração utilizada.

Não confunda **IA local** com **computador completamente isolado**. O sistema operacional, outros programas e arquivos continuam fazendo parte do ambiente de segurança.

4. SERVIDOR LOCAL E PORTA 8080

A configuração recomendada utiliza:

```
127.0.0.1:8080
```

127.0.0.1 representa o próprio computador. Não altere o host para 0.0.0.0 nem exponha a porta 8080 à rede/Internet sem compreender as implicações de segurança.

5. FIREWALL

Não abra portas no Firewall do Windows sem necessidade. Uma regra de firewall pode permitir conexões de entrada. Antes de usar comandos como `netsh advfirewall`, confirme exatamente o que está sendo liberado e por quê.

6. PENDRIVE E DISKPART

O projeto pode ser executado a partir de um pendrive. A configuração documentada é **exFAT** e **MBR**. Um pendrive anunciado como 16 GB pode apresentar aproximadamente 14,3 GB de capacidade utilizável no Windows.

ATENÇÃO: comandos do DiskPart como `c clean`, `delete` e `format` podem apagar dados. Se você não tem certeza de qual disco está selecionado, **NÃO EXECUTE** comandos destrutivos.

7. SEGURANÇA

O fato de o modelo ser local não oferece garantia de segurança absoluta. Use arquivos de fontes confiáveis, mantenha o Windows atualizado, mantenha o Windows Defender/antivírus ativo e evite executar o projeto como Administrador sem necessidade.

No Windows, determinados mecanismos de sandbox disponíveis em outras plataformas não funcionam da mesma forma. Portanto, trate o processo como software executado no seu computador e não como um ambiente totalmente isolado.

8. COMPONENTES DE TERCEIROS

O projeto utiliza componentes de terceiros, incluindo `llamafile/llama.cpp` e um modelo GGUF. Consulte as fontes originais e as respectivas licenças antes de redistribuir qualquer componente.

9. CHECKLIST — NÃO CONTINUE SE NÃO ENTENDEU

- Li este PDF inteiro.
- Li o README.md inteiro.
- Li docs/COMO-FUNCIONA-E-SEGURANCA.md.
- Entendi que o projeto executa software local.
- Entendi quando a Internet é necessária.
- Entendi o que é 127.0.0.1.
- Entendi a finalidade da porta 8080.
- Entendi os riscos de abrir uma porta no firewall.
- Entendi os riscos de usar DiskPart.
- Sei como encerrar o servidor.
- Estou utilizando um computador confiável.

10. README EMBUTIDO — GUIA RÁPIDO

Este resumo não substitui o README.md do repositório. O usuário deve abrir e ler o arquivo original antes de executar o projeto.

O que é o CHAT-IA-USB?

É um projeto para executar um modelo de IA localmente utilizando llamafile e um modelo GGUF armazenado localmente. O pendrive funciona principalmente como meio de armazenamento e transporte; o processamento ocorre no computador.

Fluxo básico

Pendrive → llamafile → modelo GGUF → CPU/GPU → servidor local → 127.0.0.1:8080

Componentes

Runtime: **llamafile 0.10.5**

Modelo: **Qwen3 4B Thinking Q4_K_M GGUF**

Sistema de arquivos recomendado: **exFAT**

Endereço local recomendado: **127.0.0.1**

Porta: **8080**

Instalação e execução

Depois de ler toda a documentação, utilize o `instalar.bat` para obter os componentes necessários e, após a instalação, utilize `iniciar.bat` para iniciar o servidor local.

Fontes

llamafile: <https://github.com/mozilla-ai/llamafile>

Modelo: https://huggingface.co/pramodlohra/Qween3_4B_thinking_finetune

Autor do projeto: **Vini Amaral**

Site: <http://viniamaral.click/>

■ **LEIA PRIMEIRO. EXECUTE DEPOIS.**

Se você não leu o README.md e o documento de funcionamento e segurança, pare aqui e leia a documentação antes de continuar.